
Taller de Redes Neuronales Artificiales

Perceptrón Multicapa para la Clasificación de Severidad de *Verticillium* sp. mediante Índices Espectrales

Clasificación multivariada, regresión logística
y análisis de dependencia espacial en escala ordinal

Variables predictoras disponibles		
Variable	Descripción	Tipo
NDVI (promedio)	Índice de Vegetación de Diferencia Normalizada	Continua
EVI (promedio)	Índice de Vegetación Mejorado	Continua
NDRE (promedio)	Índice de Borde Rojo Normalizado	Continua
GLI (promedio)	Índice de Hoja Verde	Continua
Altura media	Altura promedio de la planta (cm)	Continua
Variable respuesta: Severidad de la enfermedad (1 = sano, 2, 3, ... = niveles de severidad)		
Tamaño muestral: $n > 200$ observaciones		

2025–2026

Nota importante: Este taller requiere análisis, interpretación y decisiones propias. No es suficiente ejecutar código generado automáticamente. Se evaluará la justificación de cada decisión metodológica y la interpretación de los resultados.

1. Contexto y descripción del problema

La enfermedad causada por *Verticillium* sp. es una de las principales amenazas fitosanitarias en cultivos de alto valor económico. Su detección temprana y la clasificación precisa de su severidad son fundamentales para la toma de decisiones agronómicas. En este taller se dispone de un conjunto de datos con más de 200 observaciones de plantas, caracterizadas por cinco índices espectrales obtenidos mediante teledetección y por la altura media de la planta, con una etiqueta de severidad de la enfermedad donde **la categoría 1 corresponde a planta sana**.

El objetivo es desarrollar, evaluar y comparar modelos de clasificación basados en perceptrón multicapa (redes neuronales artificiales) y regresión logística, bajo diferentes esquemas de partición de datos, funciones de pérdida y configuraciones arquitectónicas. Adicionalmente, se explorará la dimensión espacial del problema mediante la construcción de una grilla y el análisis de dependencia espacial en escala ordinal.

2. Parte I: Clasificación múltiple de severidad con perceptrón multicapa

2.1. Exploración y preprocesamiento

Antes de entrenar cualquier modelo, la exploración y el preprocesamiento de los datos son pasos obligatorios que deben documentarse y justificarse explícitamente.

Pregunta 1. Realice un análisis exploratorio de los cinco índices espectrales y la altura media de la planta. Reporte estadísticos descriptivos por categoría de severidad, incluyendo media, desviación estándar, mínimo y máximo. ¿Observa diferencias visibles entre categorías? Justifique si considera necesaria alguna transformación o estandarización de las variables antes de entrenar la red.

Pregunta 2. Verifique si las categorías de severidad están balanceadas. En caso de desequilibrio notable, proponga y justifique al menos una estrategia para manejarlo (sobremuestreo, submuestreo, ponderación de clases u otra). Implemente la estrategia elegida y explique su efecto esperado sobre las métricas de ajuste.

2.2. Partición de datos

Una decisión fundamental en el aprendizaje supervisado es cómo dividir los datos disponibles para entrenamiento, validación y evaluación final. Esta sección requiere que compare dos esquemas y argumente cuál es más apropiado.

Pregunta 3. Implemente dos esquemas de partición:

- a) Entrenamiento / Prueba (por ejemplo, 80%–20%).

b) Entrenamiento / Validación / Prueba (por ejemplo, 70%–15%–15%).

Para cada esquema, entrene un perceptrón multicapa con la misma arquitectura inicial y compare los resultados. Explique en detalle cuál es la ventaja del esquema de tres particiones frente al de dos, en particular con respecto al riesgo de sobreajuste y a la selección de hiperparámetros.

Pregunta 4. Dado que el tamaño muestral es mayor a 200 pero no muy grande, ¿considera que sería apropiado usar validación cruzada k -fold como alternativa o complemento? Argumente su respuesta y, si decide implementarla, reporte los resultados comparativos.

2.3. Arquitectura y entrenamiento

El diseño de la arquitectura de una red neuronal involucra decisiones sobre el número de capas ocultas, el número de neuronas por capa, la función de activación y el algoritmo de optimización. Cada decisión debe estar justificada.

Pregunta 5. Entrene al menos cuatro perceptrones multicapa variando sistemáticamente:

- Número de capas ocultas: 1, 2 y 3 capas.
- Número de neuronas por capa: al menos dos configuraciones por número de capas.
- Tasa de aprendizaje: pruebe al menos tres valores (por ejemplo, 0.001, 0.01, 0.1).

Para cada configuración reporte la métrica de pérdida en entrenamiento y validación por época. ¿En qué configuraciones observa indicios de sobreajuste o subajuste? Identifíquelos gráficamente mediante las curvas de aprendizaje.

Pregunta 6. Implemente y compare dos criterios para cuantificar el error durante el entrenamiento:

- a) Función de pérdida de entropía cruzada categórica (*categorical cross-entropy*).
- b) Error cuadrático medio (*mean squared error*).

¿Cuál es más apropiado para un problema de clasificación múltiple? Fundamente su respuesta tanto teórica como empíricamente a partir de los resultados obtenidos.

2.4. Métricas de evaluación

En clasificación múltiple, una única métrica global puede ocultar diferencias importantes entre clases. Se espera un reporte completo y una interpretación crítica.

Pregunta 7. Para el modelo seleccionado como mejor en la Pregunta 5, reporte las siguientes métricas calculadas sobre el conjunto de prueba:

- Exactitud global (*accuracy*).
- Precisión, sensibilidad (*recall*) y F_1 -score por clase.
- Macro-promedio y promedio ponderado de precisión, sensibilidad y F_1 .
- Matriz de confusión completa con interpretación.
- Curva ROC y área bajo la curva (AUC-ROC) para cada clase bajo el esquema uno-contratodos, si la librería lo permite.

Interprete los resultados: ¿qué categorías de severidad son más difíciles de clasificar correctamente? ¿A qué lo atribuye?

3. Parte II: Clasificación binaria de severidad

3.1. Colapso de categorías

Esta sección requiere una decisión metodológica que **no tiene una única respuesta correcta**. Se evaluará la justificación del criterio elegido.

Pregunta 8. Proponga y justifique un criterio para colapsar las categorías de severidad en dos grupos: **sano** (severidad 1) versus **enfermo** (resto de categorías). Discuta si esta agrupación es la más apropiada desde el punto de vista agronómico o si existiría una alternativa mejor fundamentada. ¿Se pierde información relevante al hacer esta reducción?

Pregunta 9. Entrene un perceptrón multicapa para el problema binario resultante, repitiendo el esquema de partición entrenamiento/validación/prueba. Compare el desempeño con el modelo de clasificación múltiple de la Parte I en términos de las métricas comunes. ¿Mejora la clasificación al reducir el número de clases? Explique por qué o por qué no.

Pregunta 10. Reporte para el modelo binario: exactitud, precisión, sensibilidad, especificidad, F_1 -score, AUC-ROC y el umbral de clasificación óptimo según el criterio de Youden o el punto más cercano a la esquina superior izquierda de la curva ROC. Interprete cada métrica en el contexto del problema fitosanitario: ¿qué es más costoso, un falso negativo o un falso positivo?

4. Parte III: Regresión logística y comparación de modelos

4.1. Modelo de regresión logística binaria

La regresión logística constituye una línea base interpretable con la que comparar los

modelos de redes neuronales. Su análisis de coeficientes permite además identificar las variables más relevantes.

Pregunta 11. Ajuste un modelo de regresión logística binaria (sano vs. enfermo) usando la misma partición de datos que en la Parte II. Reporte los coeficientes estimados, sus errores estándar, los valores p y los intervalos de confianza al 95%. ¿Qué variables son estadísticamente significativas? ¿Tienen el signo esperado desde el punto de vista agronómico?

Pregunta 12. Aplique al menos un método de selección de variables sobre el modelo de regresión logística: puede usar selección paso a paso (*stepwise*), regularización Lasso (L_1) o Ridge (L_2), o criterios de información (AIC/BIC). ¿Cuáles son las variables más relevantes para predecir la severidad según este modelo? Compare este resultado con la importancia de variables obtenida con la red neuronal en la Pregunta 12.

Pregunta 13. Compare el modelo de regresión logística con el mejor perceptrón multicapa binario de la Parte II utilizando las mismas métricas de evaluación sobre el mismo conjunto de prueba. Construya una tabla comparativa y argumente cuál modelo elegiría para un sistema de apoyo a la decisión agronómica, considerando no solo el desempeño predictivo sino también la interpretabilidad y el costo computacional.

4.2. Importancia de variables en redes neuronales

Las redes neuronales son modelos de caja negra, pero existen estrategias para aproximar la importancia de cada variable predictora.

Pregunta 14. Implemente al menos una de las siguientes estrategias para evaluar la importancia de las variables predictoras en el perceptrón multicapa binario:

- Permutación de características (*permutation feature importance*): permute aleatoriamente cada variable de entrada en el conjunto de prueba y mida la caída en exactitud o AUC-ROC.
- Análisis de sensibilidad: evalúe cómo varía la salida de la red al cambiar sistemáticamente cada variable de entrada mientras las demás se fijan en sus valores promedio.
- Valores SHAP (*SHapley Additive exPlanations*), si dispone de la librería correspondiente.

Compare el ranking de importancia obtenido con el de la regresión logística. ¿Coinciden las variables más relevantes? ¿Qué implicaciones tiene esto para el monitoreo espectral de la enfermedad?

5. Parte IV: Análisis de dependencia espacial

5.1. Construcción de la grilla y asignación de severidad

Esta sección conecta el análisis predictivo con la dimensión espacial del problema. Se trabaja con una submuestra de 196 observaciones para construir una grilla regular.

Pregunta 15. Tome una muestra aleatoria de 196 observaciones del conjunto de datos original. Construya una grilla de 14×14 celdas y asigne cada observación a una celda de la grilla según sus coordenadas espaciales (o mediante asignación aleatoria si las coordenadas no están disponibles, justificando la decisión). Visualice la grilla mostrando la severidad asignada a cada celda con una escala de color apropiada para datos ordinales.

Pregunta 16. La severidad es una variable ordinal. Proponga y aplique al menos un método para evaluar la dependencia espacial en esta escala. Puede considerar:

- a) Índice de Moran global para datos ordinales (usando rangos o un esquema de codificación apropiado).
- b) Índice de Moran local (LISA) para identificar clústeres espaciales de alta o baja severidad.
- c) Estadístico de Geary o variograma empírico de rangos.

Reporte el estadístico elegido, su valor p y su interpretación: ¿existe dependencia espacial significativa en la distribución de la severidad?

5.2. Incorporación de coordenadas en la red neuronal

Una vez caracterizada la dependencia espacial, se explora si su incorporación explícita en el modelo predictivo mejora el desempeño clasificatorio.

Pregunta 17. Tome el mejor modelo de perceptrón multicapa obtenido en las partes anteriores (con la clasificación de su elección, múltiple o binaria) y reentrénelo incorporando las coordenadas espaciales (x, y) de cada observación como variables de entrada adicionales. Compare el desempeño con el modelo original sin coordenadas. ¿Mejora la clasificación al incluir información espacial explícita?

Pregunta 18. Explore dos formas adicionales de incorporar la información espacial:

- a) **Coordenadas como único predictor:** entrene una red neuronal usando exclusivamente las coordenadas (x, y) como entradas. ¿Tiene poder predictivo la ubicación espacial por sí sola?
- b) **Interacción multiplicativa:** construya nuevas variables $x \cdot \text{NDVI}$, $y \cdot \text{NDVI}$, $x \cdot \text{EVI}$, $y \cdot \text{EVI}$ (u otras interacciones que considere relevantes) e inclúyalas como predictores adicionales. ¿Aporta esta interacción espacial-espectral información adicional?

Para cada caso reporte las métricas de evaluación y compare con el modelo base sin coordenadas. Concluya sobre la utilidad de cada estrategia.

6. Parte V: Propuesta libre del estudiante

Esta sección evalúa la capacidad de proponer extensiones metodológicas propias, más allá de lo solicitado explícitamente en las secciones anteriores.

Pregunta 19. Propuesta metodológica propia. Proponga, justifique e implemente al menos una extensión o análisis complementario no solicitado explícitamente en este taller. Algunas posibilidades (no limitantes) son:

- Regularización por *dropout* o *early stopping* en la red neuronal y su efecto sobre el sobreajuste.
- Comparación con otro algoritmo de clasificación (árbol de decisión, Random Forest, SVM) usando las mismas particiones y métricas.
- Análisis de robustez: ¿cómo cambia el desempeño del mejor modelo ante pequeñas perturbaciones en los índices espectrales?
- Visualización de las fronteras de decisión en un espacio reducido (PCA o t-SNE de las variables de entrada).
- Estudio del efecto del ruido de medición en los índices espectrales sobre la clasificación de severidad.
- Modelado espacial explícito: uso de autoregresión espacial (SAR) o filtrado espacial previo al entrenamiento de la red.

Documente claramente el objetivo de su propuesta, la metodología empleada, los resultados obtenidos y las conclusiones.

7. Estructura del informe y criterios de evaluación

7.1. Estructura del informe

El informe debe entregarse en formato PDF generado desde R Markdown, Quarto, Jupyter Notebook o $\text{\LaTeX}$, con código reproducible adjunto o enlace al repositorio.

El informe debe contener:

1. **Introducción** (máximo 1 página): contexto del problema y objetivos.
2. **Exploración y preprocesamiento**: análisis descriptivo y decisiones tomadas.
3. **Metodología**: descripción de arquitecturas, hiperparámetros probados y criterios de selección del modelo final.

4. **Resultados:** tablas y figuras con las métricas de evaluación para todos los modelos comparados.
5. **Discusión:** interpretación de los resultados en el contexto agronómico y comparación entre modelos.
6. **Análisis espacial:** resultados de la grilla, estadístico de dependencia espacial y efecto de las coordenadas.
7. **Propuesta propia:** descripción, resultados y conclusiones.
8. **Conclusiones generales.**
9. **Código:** adjunto como apéndice o repositorio público.

7.2. Criterios de evaluación

Criterio	Peso	Descripción
Análisis exploratorio y preprocesamiento	10%	Calidad del análisis descriptivo y justificación del preprocesamiento.
Implementación de modelos	20%	Correcta implementación de las arquitecturas y particiones solicitadas.
Métricas e interpretación	20%	Reporte completo de métricas y su interpretación en contexto.
Comparación y selección	15%	Justificación de la elección del mejor modelo y comparación entre enfoques.
Análisis espacial	15%	Construcción de la grilla, estadístico de dependencia e incorporación de coordenadas.
Propuesta propia	10%	Originalidad, justificación metodológica y calidad de los resultados.
Presentación y reproducibilidad	10%	Claridad del informe, calidad de las figuras y reproducibilidad del código.
Total	100%	

Recordatorio importante. El objetivo de este taller no es obtener el mayor porcentaje de exactitud posible, sino demostrar comprensión metodológica. Se espera que cada decisión (arquitectura, partición, función de pérdida, estrategia espacial) esté acompañada de una justificación explícita basada en la teoría y en los resultados observados. Un

modelo simple bien interpretado tiene mayor valor académico que un modelo complejo sin análisis crítico.